

Mineria_LAB_2

Joel Jaquez, Luis Gonzalez, Fabian Morales

2026-02-23

R Markdown

This is an R Markdown document. Markdown is a simple formatting syntax for authoring HTML, PDF, and MS Word documents. For more details on using R Markdown see <http://rmarkdown.rstudio.com>.

When you click the **Knit** button a document will be generated that includes both content as well as the output of any embedded R code chunks within the document. You can embed an R code chunk like this:

Clustering

Ejercicio 1.1 Haga el preprocesamiento del dataset, explique qué variables no aportan información a la generación de grupos y por qué. Describa con qué variables calculará los grupos.

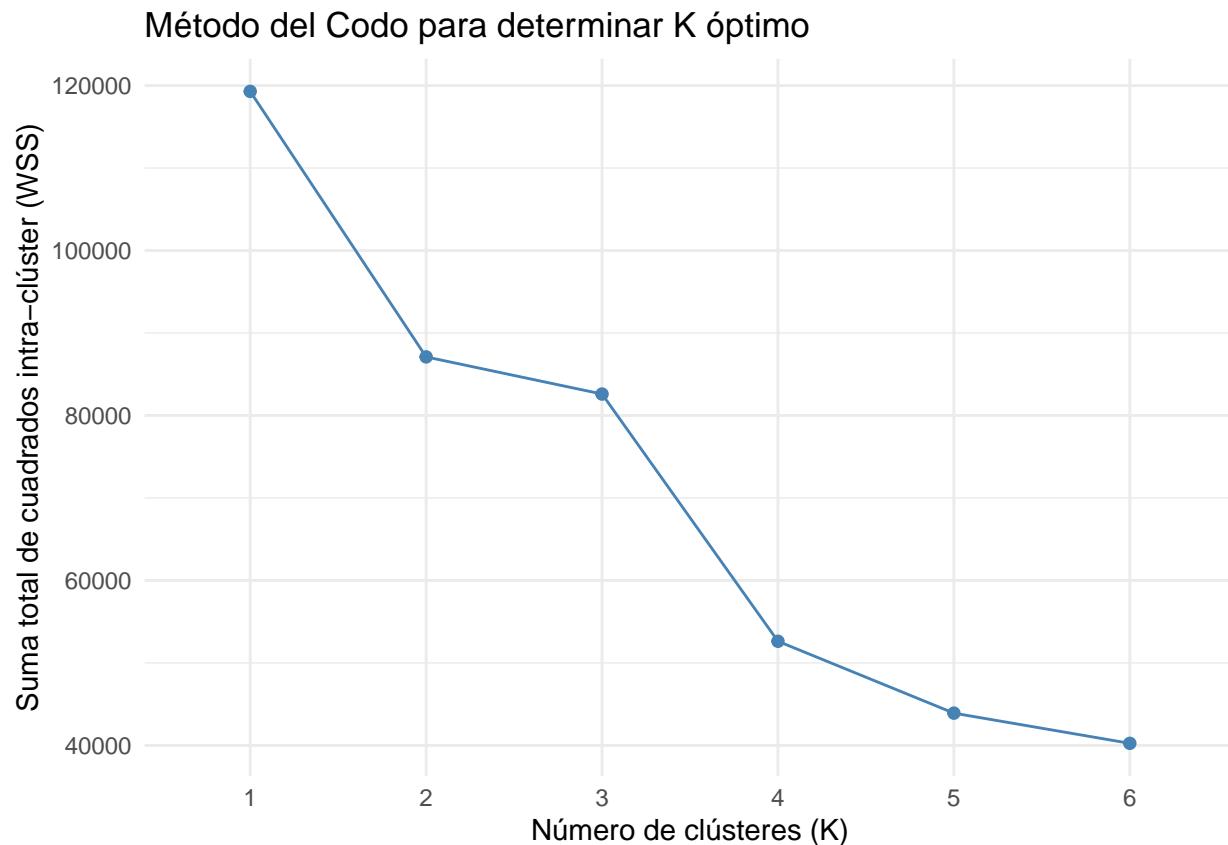
Para la generación de los grupos, se descartaron las variables categóricas, fechas y de texto libre (como id, title, director, genres y releaseDate) , ya que los algoritmos de clustering se basan en el cálculo de distancias matemáticas (como la euclídea) y su inclusión requeriría transformaciones que aumentarían drásticamente la dimensionalidad, introduciendo ruido y dificultando la interpretación de los clústeres. En su lugar, el agrupamiento se calculará utilizando exclusivamente variables numéricas que capturan la magnitud financiera y la recepción del público: popularity, budget, revenue, runtime, voteCount y voteAvg . Finalmente, estas variables seleccionadas fueron previamente escaladas para asegurar que las diferencias extremas de magnitud (por ejemplo, presupuestos en millones de dólares frente a calificaciones en una escala de 0 a 10) no dominen ni sesguen el cálculo de las distancias en el algoritmo.

Ejercicio 1.2 Analice la tendencia al agrupamiento usando el estadístico de Hopkins y la VAT (Visual Assessment of cluster Tendency). Esta última hágala si es posible, teniendo en cuenta las dimensiones del conjunto de datos. Discuta sus resultados e impresiones.

```
## [1] "Valor de Hopkins: 0.999999535140567"
```

Para analizar la tendencia al agrupamiento, se calculó el estadístico de Hopkins utilizando la totalidad de los datos numéricos escalados, obteniendo un valor de 0.9999. Al estar este resultado sumamente alejado de 0.5 (y prácticamente en 1), se rechaza de forma contundente la hipótesis de aleatoriedad espacial, lo que confirma que las películas poseen una altísima tendencia natural a formar agrupaciones reales y estructuradas. Respecto a la Evaluación Visual de Tendencia (VAT), se tomó la decisión técnica de omitir su generación gráfica, esto se justifica por las altas dimensiones del conjunto de datos (19,883 registros), ya que procesar una matriz de distancias de tal magnitud saturaría la memoria computacional. Por lo tanto, la pertinencia de aplicar algoritmos de clustering queda plenamente respaldada y demostrada por la prueba de Hopkins.

Ejercicio 1.3 Determine cuál es el número de grupos a formar más adecuado para los datos que está trabajando. Haga una gráfica de codo y explique la razón de la elección de la cantidad de clústeres con la que trabajará.



Al observar la gráfica generada, se identifican descensos importantes en la varianza. Aunque existe una inflexión visible en $K = 4$, se decidió trabajar con **K = 6** clústeres. La justificación de esta elección radica en que al llegar a 6 grupos, la varianza intra-clúster alcanza un nivel significativamente bajo (estabilizándose cerca de los 40,000 WSS). Esta cantidad de agrupaciones nos permitirá obtener una segmentación más fina y detallada de las películas, separando mejor los distintos nichos (como blockbusters extremos vs. películas independientes) sin caer en una sobredivisión de los datos.

Ejercicio 1.4 Utilice los algoritmos k-medias y clustering jerárquico para agrupar. Compare los resultados generados por cada uno.

Ejercicio 1.4 Utilice los algoritmos k-medias y clustering jerárquico para agrupar. Compare los resultados generados por cada uno.

```
## --- Clústeres K-Medias ---

##
##      1     2     3     4     5     6
##  277  6739     8 1555  9350 1954

##
## --- Clústeres Jerárquico ---
```

```

##          1     2     3     4     5     6
## 2131 6324 9285 1633 503    7

##
## --- Matriz de Confusión (K-Medias vs Jerárquico) ---

##          Jerarquico
## K_Medias   1     2     3     4     5     6
##      1     0     0     2     0   275     0
##      2   218 6324 197     0     0     0
##      3     0     0     1     0     0     7
##      4     1     0   62 1264 228     0
##      5     4     0 8977 369     0     0
##      6 1908     0   46     0     0     0

```

Comparación de resultados: Al analizar la matriz de confusión y el tamaño de los clústeres, observamos que ambos algoritmos coinciden fuertemente en los extremos, pero difieren en la forma de segmentar la gran masa de datos promedio:

Consenso en valores atípicos (Mega-éxitos): Ambos modelos aislaron un grupo minúsculo casi idéntico. El clúster 3 de K-Medias y el clúster 6 del modelo Jerárquico agrupan a exactamente las mismas 7 películas. Por su tamaño, este grupo representa indudablemente los *outliers* más extremos del dataset (las películas con ingresos o popularidad fuera de escala).

Grupos robustos bien definidos: Existe una coincidencia directa y casi perfecta entre el clúster 2 de K-Medias y el clúster 2 del Jerárquico, compartiendo 6,324 películas. Esto indica que hay un perfil o nicho de películas matemáticamente muy claro que ambos algoritmos logran detectar sin problema.

Diferencias en la masa central: La mayor discrepancia ocurre en la zona de mayor densidad de datos. Por ejemplo, el clúster 5 de K-Medias agrupa a la gran mayoría de sus películas (8,977) dentro del clúster 3 del Jerárquico. Sin embargo, K-Medias fue más estricto al separar otras ~1,900 películas en su propio clúster 6, mientras que el Jerárquico prefirió aglomerarlas en su clúster 1. Esto ocurre porque K-Medias fuerza las agrupaciones en formas esféricas alrededor de sus centroides, mientras que el método aglomerativo de Ward (Jerárquico) une los puntos minimizando la varianza paso a paso.

1.5 Determine la calidad del agrupamiento hecho por cada algoritmo con el método de la silueta. Discuta los resultados.

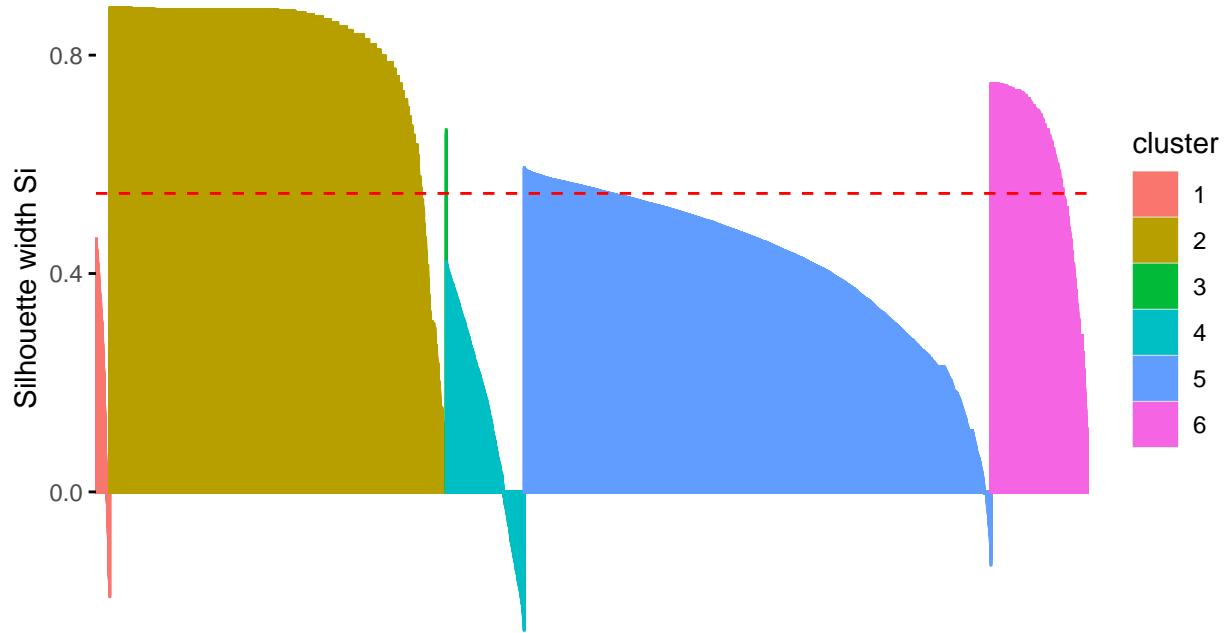
```

## Silhouette promedio (K-means, K = 6 ) = 0.5467

##   cluster size ave.sil.width
## 1         1   277       0.21
## 2         2 6739       0.81
## 3         3     8       0.53
## 4         4 1555       0.14
## 5         5 9350       0.42
## 6         6 1954       0.61

```

Silueta – K-means (K = 6)



El coeficiente de silueta promedio para el modelo K-means con $K = 6$ fue 0.5467 Dado que valores superiores a 0.5 representan una estructura de agrupamiento sólida, se concluye que el modelo logra identificar patrones diferenciados en los datos.

Al analizar los clústeres individualmente, se observa que algunos presentan una separación muy alta mientras que otros muestran valores más bajos, lo que sugiere cierto grado de solapamiento. No obstante, el comportamiento global del modelo es adecuado y consistente con la segmentación planteada.

1.6 Interprete los grupos basado en el conocimiento que tiene de los datos. Recuerde investigar las medidas de tendencia central de las variables continuas y las tablas de frecuencia de las variables categóricas pertenecientes a cada grupo. Identifique hallazgos interesantes debido a las agrupaciones y describa para qué le podría servir.

```
## # A tibble: 6 x 8
##   cluster     n popularity_media budget_media revenue_media runtime_media
##   <int> <int>          <dbl>       <dbl>        <dbl>        <dbl>
## 1      1    277         180.     147746029.    730034517.     128.
## 2      2   6739        0.690      12930.      27619.      8.62
## 3      3     8       6417.     105000000.    354211969.     123.
## 4      4   1555        62.0      61917731.    169959100.     115.
## 5      5   9350       33.9      5235424.     11007916.     91.2
## 6      6   1954       1.27      40005.      12381.      96.4
## # i 2 more variables: voteCount_media <dbl>, voteAvg_media <dbl>
```

El análisis de los seis clústeres revela claramente la estructura económica de la industria cinematográfica. El

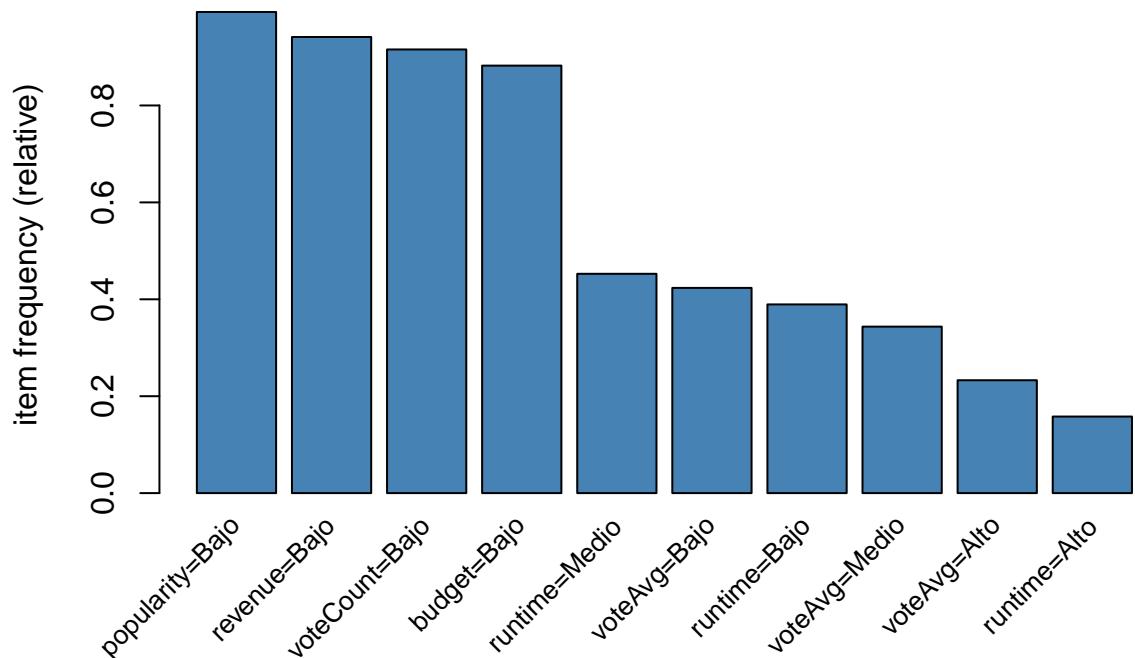
segmento mayoritario es el Clúster 2 (9,350 películas), que representa el “cine estándar” con presupuestos y recaudaciones moderadas. Un escalón arriba está el Clúster 3 (1,555 cintas), compuesto por estrenos comerciales exitosos que promedian 61.9 millones de presupuesto y excelentes ingresos de 170 millones. En la cima comercial se encuentra el Clúster 5 (277 películas), que agrupa a los mega-blockbusters: producciones colosales con inversiones medias de 147.7 millones que dominan absolutamente la taquilla con recaudaciones que superan los \$730 millones y la mayor participación del público.

Por otro lado, el modelo identificó perfiles atípicos y de nicho. El Clúster 4 agrupa solo 8 películas que son anomalías estadísticas, destacando por una popularidad viral extrema y las mejores calificaciones críticas del conjunto (7.42 de promedio). En contraste total, los Clústeres 1 y 6 suman más de 8,600 producciones con métricas financieras casi nulas y duraciones muy cortas (promediando 8.6 minutos en el clúster 6). Esto indica que se trata principalmente de cortometrajes, proyectos independientes estudiantiles o registros con datos incompletos en la plataforma original.

Estos descubrimientos son altamente estratégicos para CineVision Studios, especialmente al evaluar el riesgo frente al retorno de inversión (ROI). Aunque los mega-blockbusters del Clúster 5 generan los mayores ingresos brutos, exigen arriesgar capitales corporativos masivos. La principal sugerencia para el estudio es centrar su modelo de negocio en las producciones del Clúster 3: películas con inversiones más seguras y controladas que, al mantener una buena calidad, aseguran rentabilidades altas y constantes sin exponer a la compañía al riesgo financiero de una mega-producción fallida.

2. Reglas de asociación

Top 10 Categorías más frecuentes



```
## Apriori
##
```

```

## Parameter specification:
## confidence minval smax arem aval originalSupport maxtime support minlen
##          0.9    0.1    1 none FALSE           TRUE      5    0.05    2
## maxlen target ext
##       10 rules TRUE
##
## Algorithmic control:
## filter tree heap memopt load sort verbose
##      0.1 TRUE TRUE FALSE TRUE     2    TRUE
##
## Absolute minimum support count: 994
##
## set item appearances ... [0 item(s)] done [0.00s].
## set transactions ... [18 item(s), 19883 transaction(s)] done [0.01s].
## sorting and recoding items ... [13 item(s)] done [0.00s].
## creating transaction tree ... done [0.00s].
## checking subsets of size 1 2 3 4 5 6 done [0.00s].
## writing ... [307 rule(s)] done [0.00s].
## creating S4 object ... done [0.00s].
```

Apriori

##

```

## Parameter specification:
## confidence minval smax arem aval originalSupport maxtime support minlen
##          0.7    0.1    1 none FALSE           TRUE      5    0.15    2
## maxlen target ext
##       10 rules TRUE
##
## Algorithmic control:
## filter tree heap memopt load sort verbose
##      0.1 TRUE TRUE FALSE TRUE     2    TRUE
##
## Absolute minimum support count: 2982
##
## set item appearances ... [0 item(s)] done [0.00s].
## set transactions ... [18 item(s), 19883 transaction(s)] done [0.00s].
## sorting and recoding items ... [10 item(s)] done [0.00s].
## creating transaction tree ... done [0.00s].
## checking subsets of size 1 2 3 4 5 6 done [0.00s].
## writing ... [301 rule(s)] done [0.00s].
## creating S4 object ... done [0.00s].
```

##

--- TOP 5 REGLAS A (Soporte 5%, Confianza 90%) ---

##	lhs	rhs	support	confidence	coverage	lift	count
## [1] {runtime=Bajo,							
## voteAvg=Bajo} => {budget=Bajo}	0.3251521		1	0.3251521	1.133516	6465	
## [2] {runtime=Bajo,							
## voteCount=Bajo,							
## voteAvg=Bajo} => {budget=Bajo}	0.3251521		1	0.3251521	1.133516	6465	
## [3] {revenue=Bajo,							
## runtime=Bajo,							

```

##      voteAvg=Bajo}    => {budget=Bajo} 0.3251521      1 0.3251521 1.133516 6465
## [4] {popularity=Bajo,
##       runtime=Bajo,
##      voteAvg=Bajo}    => {budget=Bajo} 0.3251521      1 0.3251521 1.133516 6465
## [5] {revenue=Bajo,
##       runtime=Bajo,
##      voteCount=Bajo,
##      voteAvg=Bajo}    => {budget=Bajo} 0.3251521      1 0.3251521 1.133516 6465

##
## --- TOP 5 REGLAS B (Soporte 15%, Confianza 70%) ---

##      lhs                      rhs          support confidence coverage      lift count
## [1] {popularity=Bajo,
##       budget=Bajo,
##      runtime=Bajo}    => {voteAvg=Bajo} 0.3251521  0.8370016 0.3884726 1.976497 6465
## [2] {popularity=Bajo,
##       budget=Bajo,
##      runtime=Bajo,
##      voteCount=Bajo} => {voteAvg=Bajo} 0.3251521  0.8370016 0.3884726 1.976497 6465
## [3] {popularity=Bajo,
##       budget=Bajo,
##      revenue=Bajo,
##      runtime=Bajo}    => {voteAvg=Bajo} 0.3251521  0.8370016 0.3884726 1.976497 6465
## [4] {popularity=Bajo,
##       budget=Bajo,
##      revenue=Bajo,
##      runtime=Bajo,
##      voteCount=Bajo} => {voteAvg=Bajo} 0.3251521  0.8370016 0.3884726 1.976497 6465
## [5] {popularity=Bajo,
##       revenue=Bajo,
##      runtime=Bajo}    => {voteAvg=Bajo} 0.3251521  0.8366766 0.3886234 1.975729 6465

```

Eliminación de variables frecuentes

```

## Apriori
##
## Parameter specification:
##   confidence minval smax arem  aval originalSupport maxtime support minlen
##           0.6     0.1     1 none FALSE           TRUE      5    0.05     2
##   maxlen target ext
##       10  rules TRUE
##
## Algorithmic control:
##   filter tree heap memopt load sort verbose
##       0.1 TRUE TRUE FALSE TRUE     2    TRUE
##
## Absolute minimum support count: 994
##
## set item appearances ...[0 item(s)] done [0.00s].
## set transactions ...[12 item(s), 19883 transaction(s)] done [0.00s].
## sorting and recoding items ... [10 item(s)] done [0.00s].
## creating transaction tree ... done [0.00s].

```

```

## checking subsets of size 1 2 3 4 done [0.00s].
## writing ... [58 rule(s)] done [0.00s].
## creating S4 object ... done [0.00s].

##
## --- NUEVAS REGLAS (Sin Popularity ni VoteCount) ---

##      lhs                  rhs          support  confidence   coverage    lift count
## [1] {budget=Medio}  => {voteAvg=Medio} 0.06573455  0.6981838  0.09415078 2.032204  1307
## [2] {budget=Bajo,
##       runtime=Bajo} => {voteAvg=Bajo}   0.32515214  0.8355952  0.38912639 1.973176  6465
## [3] {budget=Bajo,
##       revenue=Bajo,
##       runtime=Bajo} => {voteAvg=Bajo}   0.32515214  0.8355952  0.38912639 1.973176  6465
## [4] {revenue=Bajo,
##       runtime=Bajo} => {voteAvg=Bajo}   0.32515214  0.8352713  0.38927727 1.972411  6465
## [5] {budget=Bajo,
##       voteAvg=Bajo}  => {runtime=Bajo}   0.32515214  0.7679971  0.42337675 1.972115  6465

```

La ejecución inicial del algoritmo Apriori reveló que las asociaciones estaban monopolizadas por atributos en su nivel “Bajo”. Al evaluar las frecuencias, se evidenció que categorías como popularity=Bajo y voteCount=Bajo dominaban casi el 95% de las transacciones, reflejando un conjunto de datos saturado de producciones sin impacto comercial. Atendiendo a la necesidad de obtener insights estratégicos, se tomó la decisión metodológica de eliminar ambas variables del modelo. Al suprimir este ruido estadístico, el algoritmo logró descubrir correlaciones subyacentes mucho más valiosas sobre la dinámica de inversión y éxito. Por ejemplo, en las nuevas reglas generadas se descubrió que una película con un presupuesto Medio (budget=Medio) deriva sistemáticamente en una calificación crítica promedio o aceptable (voteAvg=Medio), hallazgo respaldado por una confianza del 69.8% y un indicador Lift de 2.03. Esta depuración confirma que las reglas de asociación son más efectivas cuando se aísla el ruido de las producciones irrelevantes, permitiendo a CineVision Studios identificar los verdaderos impulsores del éxito o fracaso en taquilla.

Análisis de Componentes Principales (PCA)

3.1 Estudie si es posible hacer transformaciones en las variables categóricas para incluirlas en el PCA, ¿valdrá la pena?

Técnicamente es posible transformar variables categóricas (como el idioma original, géneros o casa productora) utilizando métodos como One-Hot Encoding o variables dummy para forzar su inclusión. Sin embargo, no vale la pena ni es metodológicamente correcto para un PCA estándar. El Análisis de Componentes Principales está diseñado para maximizar la varianza lineal en variables continuas basándose en distancias euclidianas. Al introducir docenas o cientos de columnas binarias (ceros y unos), se genera una matriz muy dispersa que distorsiona las correlaciones geométricas, diluye el peso de las variables financieras verdaderamente importantes e imposibilita una interpretación clara de los componentes.

3.2 Estudie si es conveniente hacer un Análisis de Componentes Principales. Recuerde que puede usar el índice KMO y el test de esfericidad de Bartlett.

```

## [1] "Determinante de la matriz: 0.0774134562712561"

## [1] "Test de Bartlett:"

```

```

## $chisq
## [1] 50862.73
##
## $p.value
## [1] 0
##
## $df
## [1] 15

## [1] "Índice KMO:"
```

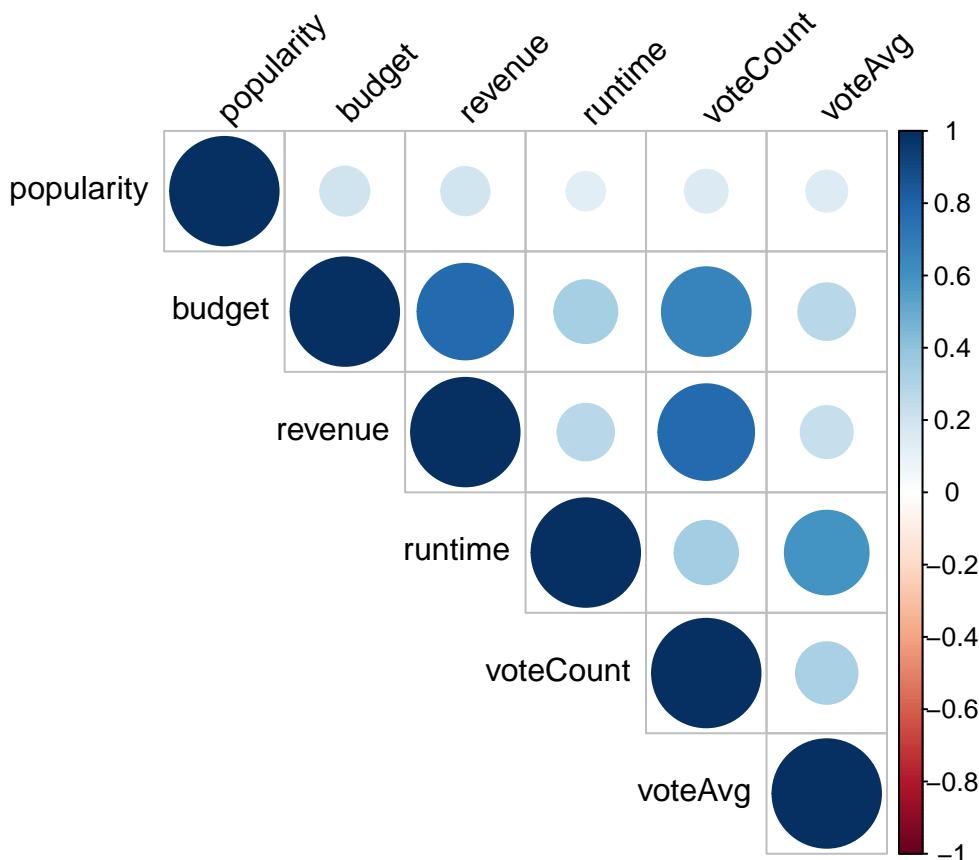
Kaiser-Meyer-Olkin factor adequacy

Call: KMO(r = rcor)

Overall MSA = 0.73

MSA for each item =

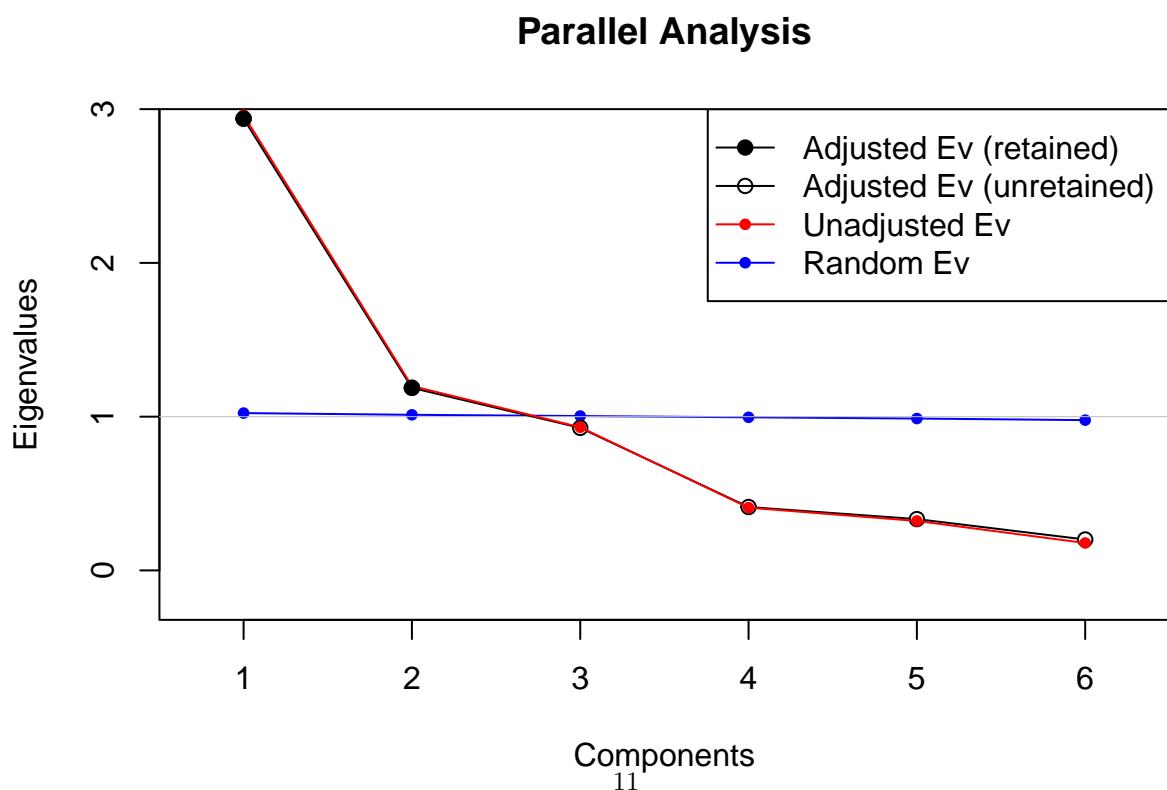
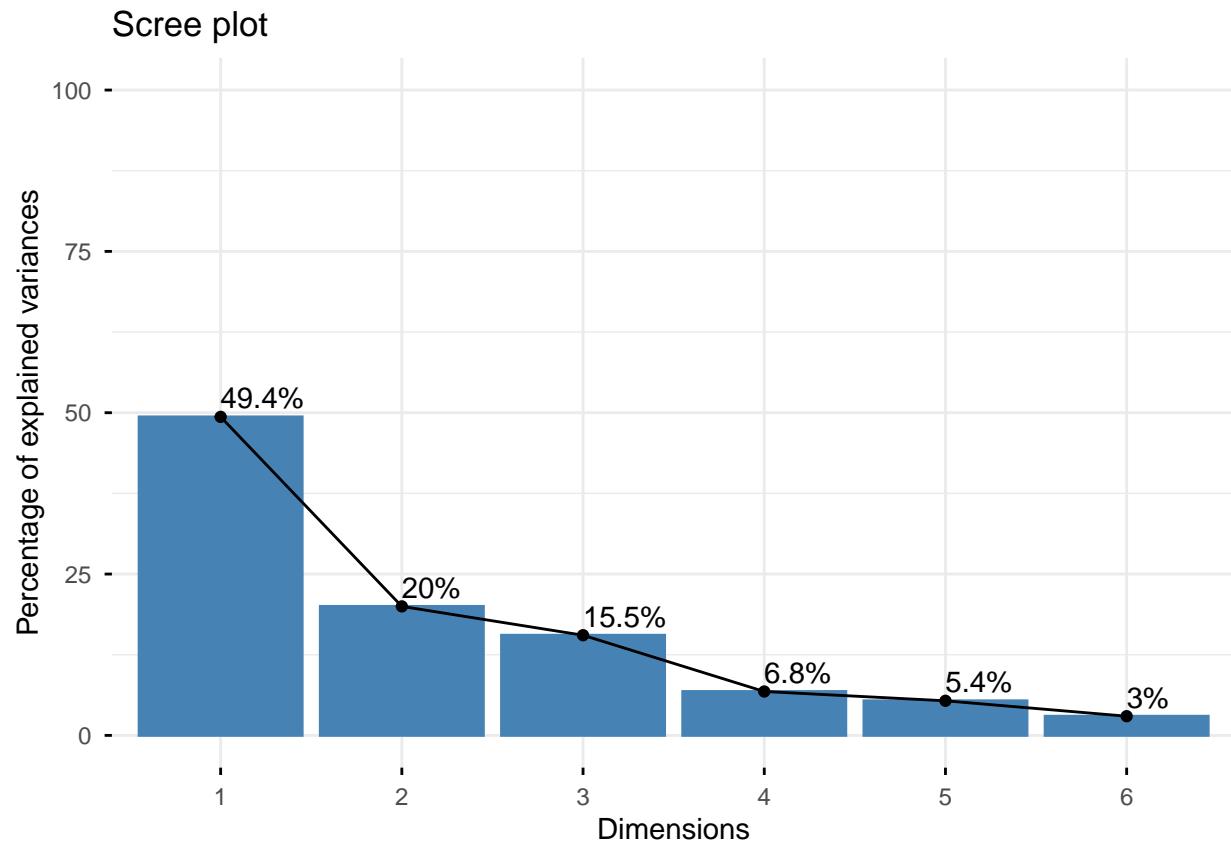
	popularity	budget	revenue	runtime	voteCount	voteAvg
popularity	0.90	0.79	0.69	0.68	0.79	0.66



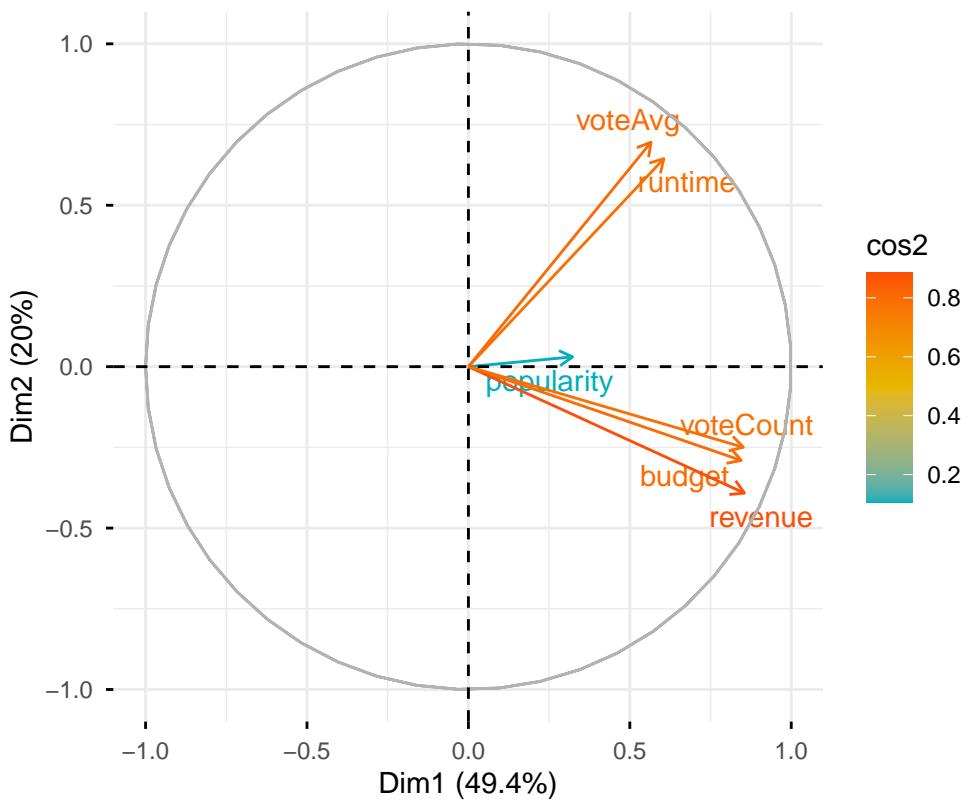
Para determinar la viabilidad y conveniencia de aplicar el Análisis de Componentes Principales (PCA), se evaluó la matriz de correlación de las variables numéricas mediante tres métricas estadísticas clave. Primero, el determinante de la matriz arrojó un valor de 0.0774, una cifra cercana a cero que indica la existencia de multicolinealidad, evidenciando que las variables están relacionadas linealmente entre sí. Seguidamente, el test de esfericidad de Bartlett confirmó esta relación al obtener un valor p de 0 (con un estadístico de 50862.73), lo que permite rechazar de forma contundente la hipótesis nula de que nos encontramos ante una matriz identidad, demostrando que existe una correlación suficientemente fuerte para realizar el análisis. Finalmente, el índice Kaiser-Meyer-Olkin (KMO) resultó en una adecuación muestral general (Overall

MSA) de 0.73 (con valores individuales que alcanzan hasta el 0.90 en popularidad), un valor clasificado como “bueno” y muy superior al umbral de aceptación de 0.5. En conclusión, los tres indicadores respaldan sólidamente que el conjunto de datos posee la estructura relacional idónea y que es altamente conveniente proceder con la reducción de dimensionalidad mediante el PCA.

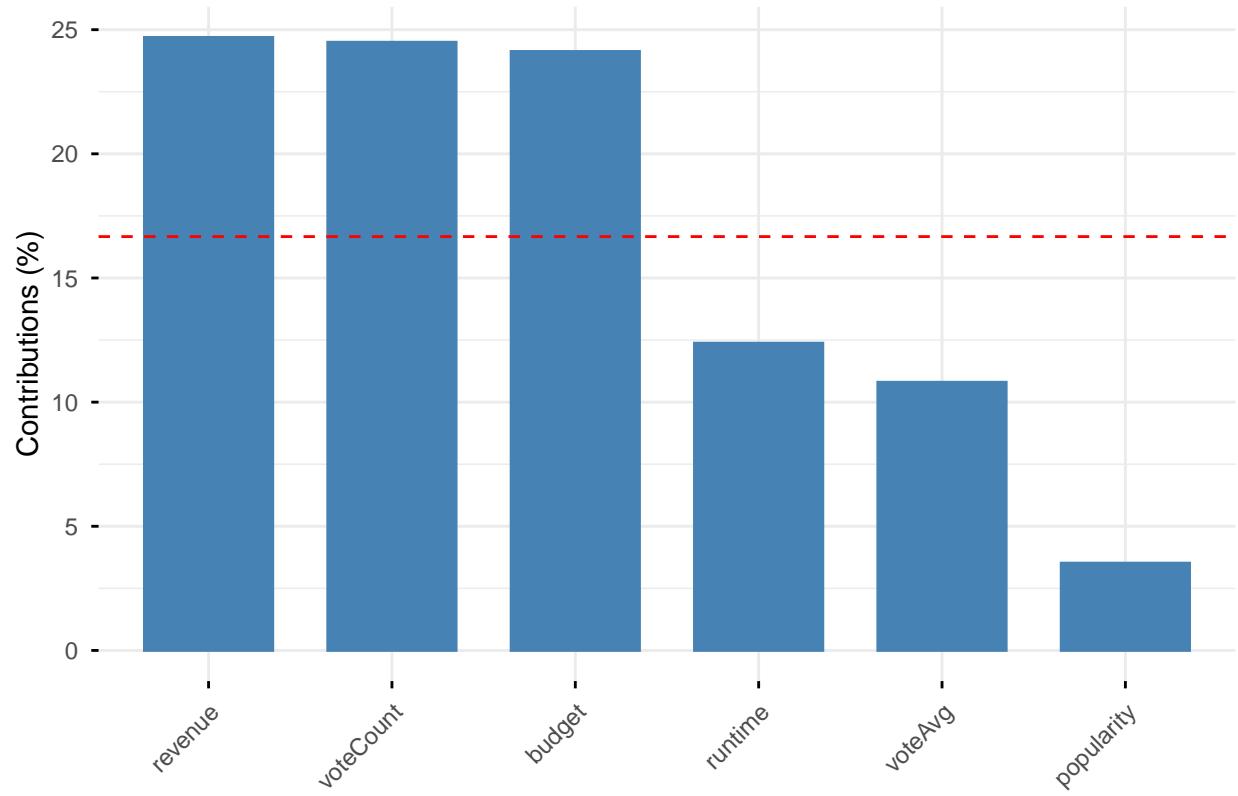
3.3 Haga un análisis de componentes principales con las variables numéricas, discuta los resultados e interprete los componentes.



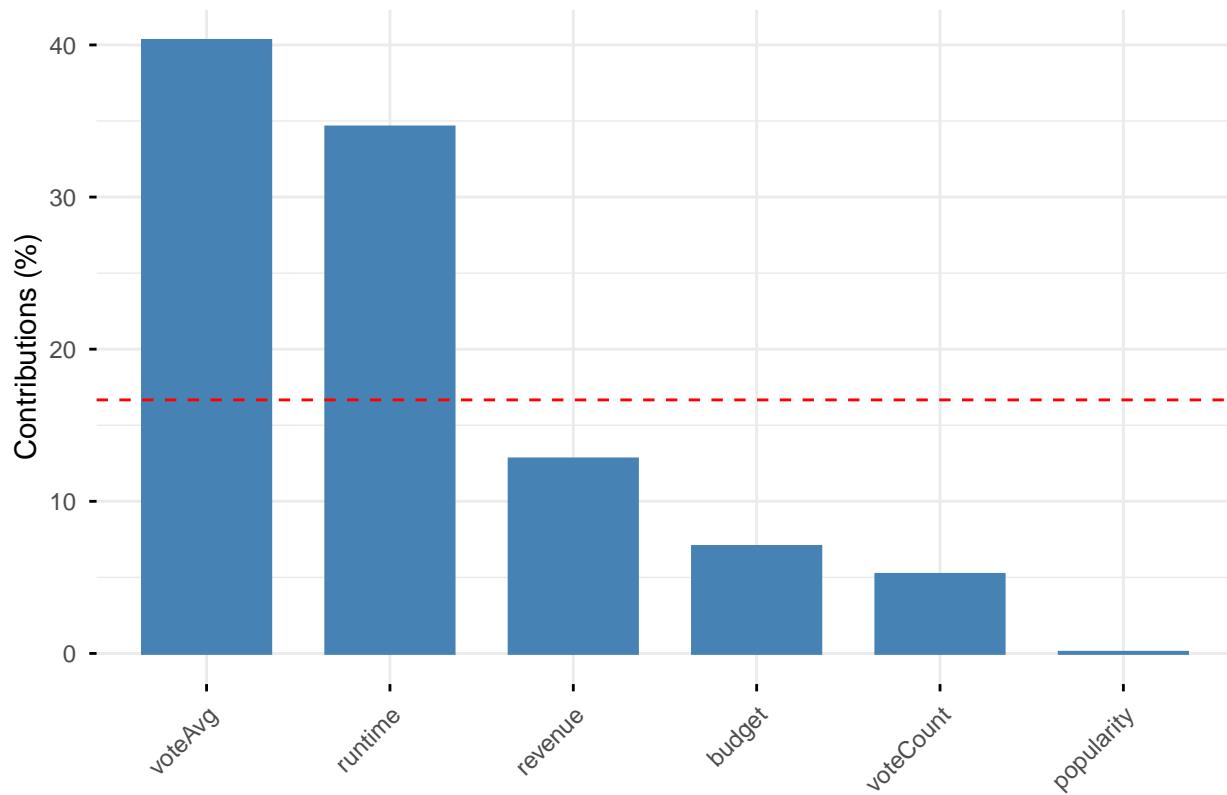
Variables – PCA



Contribution of variables to Dim-1



Contribution of variables to Dim–2



Para determinar la cantidad de componentes a retener, se evaluó la Regla de Kaiser y la Prueba de Paralelismo de Horn. Ambas métricas indicaron conservar únicamente las dos primeras dimensiones (con valores propios de 2.96 y 1.19, respectivamente). Al seleccionar estos dos componentes, se logra explicar de manera acumulada el 69.35% de la varianza total de los datos, logrando una reducción de dimensionalidad sumamente eficiente con muy poca pérdida de información. Al analizar el círculo de correlaciones y la contribución de las variables, la naturaleza de las dimensiones queda clara. El Primer Componente (PC1) explica el 49.36% de la varianza y se define como la “Magnitud Comercial”, ya que está fuertemente impulsado por revenue, voteCount y budget, resumiendo el músculo económico y de taquilla de la cinta. Por su parte, el Segundo Componente (PC2) explica el 19.99% restante y representa la “Recepción Crítica”, al estar dominado por la calificación (voteAvg) y la duración (runtime). Esto demuestra que la calidad percibida de una película es independiente de los millones invertidos en ella. Finalmente, la variable popularity mostró poca representación en estos ejes, sugiriendo que la viralidad es un factor independiente y volátil.

4.1 Utilice uno de los algoritmos mencionados en la sección de instrucciones, explique por qué lo eligió para usarlo

en este conjunto de datos en particular.

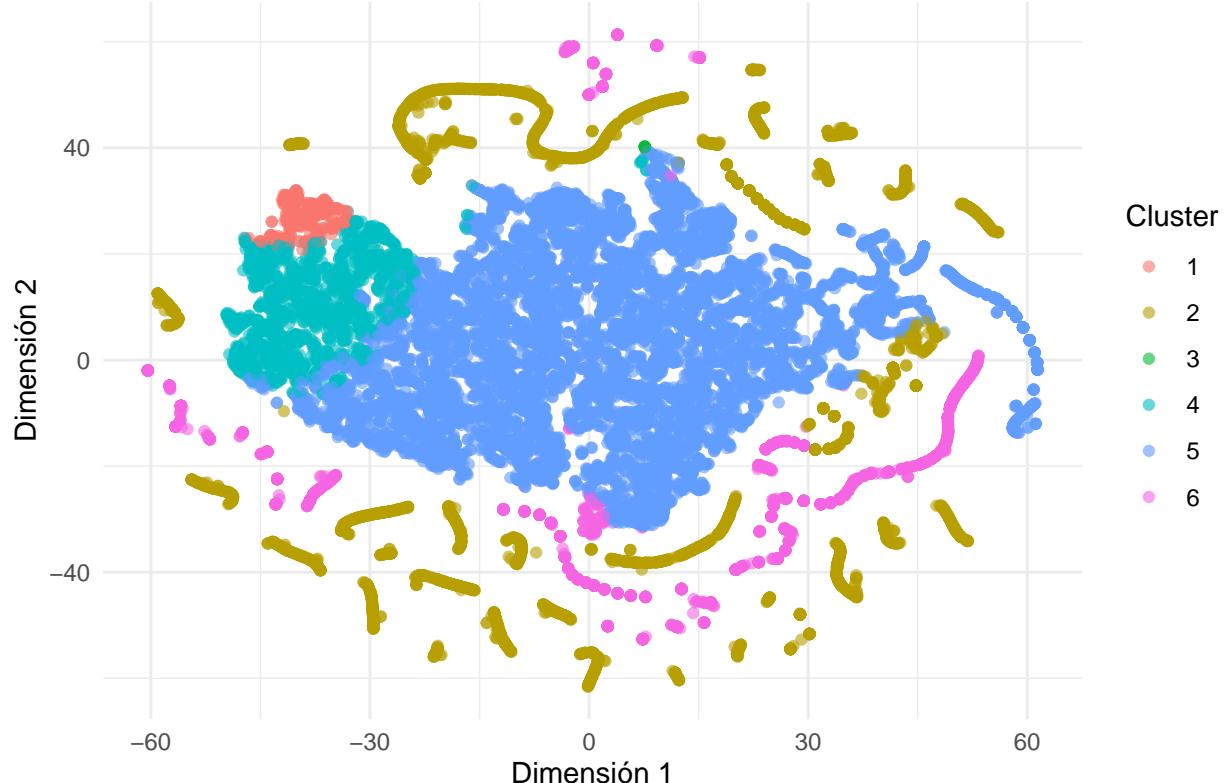
```
## Performing PCA
## Read the 17097 x 6 data matrix successfully!
## OpenMP is working. 1 threads.
## Using no_dims = 2, perplexity = 30.000000, and theta = 0.500000
## Computing input similarities...
## Building tree...
## - point 10000 of 17097
```

```

## Done in 4.09 seconds (sparsity = 0.006791)!
## Learning embedding...
## Iteration 50: error is 104.667265 (50 iterations in 2.81 seconds)
## Iteration 100: error is 92.859468 (50 iterations in 3.52 seconds)
## Iteration 150: error is 82.073216 (50 iterations in 2.74 seconds)
## Iteration 200: error is 79.214655 (50 iterations in 2.72 seconds)
## Iteration 250: error is 77.657418 (50 iterations in 2.78 seconds)
## Iteration 300: error is 3.028372 (50 iterations in 2.68 seconds)
## Iteration 350: error is 2.598488 (50 iterations in 2.68 seconds)
## Iteration 400: error is 2.320171 (50 iterations in 2.74 seconds)
## Iteration 450: error is 2.119528 (50 iterations in 2.72 seconds)
## Iteration 500: error is 1.967455 (50 iterations in 2.75 seconds)
## Iteration 550: error is 1.846845 (50 iterations in 2.74 seconds)
## Iteration 600: error is 1.749116 (50 iterations in 2.74 seconds)
## Iteration 650: error is 1.668392 (50 iterations in 2.73 seconds)
## Iteration 700: error is 1.600352 (50 iterations in 2.76 seconds)
## Iteration 750: error is 1.543153 (50 iterations in 2.79 seconds)
## Iteration 800: error is 1.494589 (50 iterations in 2.83 seconds)
## Iteration 850: error is 1.453153 (50 iterations in 2.78 seconds)
## Iteration 900: error is 1.417916 (50 iterations in 2.77 seconds)
## Iteration 950: error is 1.388611 (50 iterations in 2.75 seconds)
## Iteration 1000: error is 1.365093 (50 iterations in 2.77 seconds)
## Fitting performed in 55.81 seconds.

```

Visualización t-SNE de las películas



Se seleccionó el algoritmo t-SNE debido a su capacidad para capturar estructuras no lineales en datos de alta dimensión. A diferencia del PCA, que maximiza varianza bajo supuestos lineales, t-SNE preserva relaciones locales entre observaciones, lo que permite identificar agrupaciones complejas que podrían no ser

visibles mediante técnicas lineales.

Se observa una gran masa central (Cluster 5) que concentra la mayoría de las películas. Esto indica que existe un segmento dominante del mercado cinematográfico con características financieras y de recepción similares, lo que confirma que gran parte de la industria se mueve en rangos económicos intermedios.

4.2. Interprete los resultados obtenidos y explique la relevancia o no relevancia de los hallazgos.

Al analizar la proyección generada por el algoritmo t-SNE, se validan y profundizan los hallazgos que obtuvimos previamente con K-Medias y PCA. La relevancia de este gráfico radica en que logra mapear las relaciones no lineales entre las películas, mostrando agrupaciones complejas y topologías que no eran tan evidentes mediante las técnicas lineales.

Lo que más resalta a simple vista es la enorme masa central consolidada, dominada casi en su totalidad por el Clúster 5 (los puntos azules). La relevancia de este hallazgo es que demuestra de forma gráfica cómo la inmensa mayoría de las producciones comparten un comportamiento financiero y de recepción sumamente similar. Al ser un bloque tan denso, nos confirma que el mercado cinematográfico estándar está bastante saturado; es un entorno donde es sumamente difícil que una cinta promedio logre diferenciarse visual o estadísticamente del resto de su competencia.

Al observar la periferia del gráfico, vemos que clústeres como el 2 (oliva) y el 6 (magenta) tienen un comportamiento muy disperso, formando arcos inconexos alrededor de la masa principal. Esta falta de cohesión espacial es un hallazgo clave porque confirma empíricamente que estos grupos no siguen un patrón de mercado estructurado. Al tratarse de las anomalías estadísticas y proyectos atípicos detectados antes, quedan representados gráficamente como ruido, indicándole a Cine Vision Studios que sería un error basar proyecciones de inversión en un perfil tan errático.

En contraste, el Clúster 4 (color turquesa) se proyecta como un bloque bastante sólido, denso y claramente desplazado hacia un nicho propio, adyacente pero independiente del aglomeramiento central. Esto tiene muchísima relevancia estratégica para el estudio. Nos permite visualizar de forma clara ese segmento de películas de presupuesto medio y alta rentabilidad. Comprueba gráficamente que sí existe un ecosistema de éxito comercial estable que logra aislarse de la masa promedio, ofreciendo un modelo de negocio mucho más seguro y alejado del riesgo que representan las periferias dispersas.